📊 Exploratory Data Analysis (EDA) — Dataset NVD CVE

Proyek: **RedSim — AI-Assisted Security Analytics Prototype**

Detail	Keterangan
Mata Kuliah	Kecerdasan Buatan untuk Keamanan (KSI251525)
Dosen	Zuliar Efendi, M.Kom
Kelompok	8
Milestone	2 — Data Understanding & EDA
Dataset	NVD (National Vulnerability Database) CVE 2025–2026
Sumber	https://nvd.nist.gov/

Tujuan Notebook

1. Memahami struktur dan karakter dataset keamanan (NVD CVE).
2. Membuat Data Dictionary untuk fitur-fitur utama.
3. Melakukan Data Profiling: shape, tipe data, missing values, duplikasi, distribusi label.
4. Membuat visualisasi yang relevan untuk menemukan pola awal.
5. Menyusun temuan EDA dan rencana preprocessing.

---

1. Setup & Import Library

```
# Install library (jika dijalankan di Google Colab)
!pip install pandas matplotlib seaborn wordcloud -q
```

```
import json
import os
import glob
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import seaborn as sns
from collections import Counter
from datetime import datetime
import warnings
warnings.filterwarnings('ignore')

# Konfigurasi visual
plt.rcParams.update({
    'figure.figsize': (12, 6),
    'font.size': 11,
    'axes.titlesize': 14,
    'axes.labelsize': 12,
    'figure.dpi': 100,
    'savefig.dpi': 150
})
sns.set_theme(style='whitegrid', palette='Set2')

print('✅ Library berhasil diimport.')
print(f'Pandas: {pd.__version__}')
print(f'Waktu eksekusi: {datetime.now().strftime("%Y-%m-%d %H:%M:%S")}')
```

```
✅ Library berhasil diimport.
Pandas: 2.2.3
Waktu eksekusi: 2026-09-15 07:49:24
```

---

2. Load Dataset NVD CVE (2025–2026)

Dataset NVD (National Vulnerability Database) berisi data kerentanan keamanan siber yang dipublikasikan secara global. Setiap record merepresentasikan **satu CVE (Common Vulnerabilities and Exposures)** — yaitu satu kerentanan keamanan yang sudah teridentifikasi dan terdaftar resmi.

Mengapa dataset ini relevan untuk RedSim?

RedSim menggunakan data CVE/CWE sebagai **knowledge base** untuk:

- Mengidentifikasi jenis kerentanan pada target yang dipindai
- Memetakan temuan ke standar keamanan global (CVSS, CWE, MITRE ATT&CK)
- Memberikan skor keamanan dan rekomendasi remediasi

```
# ============================================================
# KONFIGURASI PATH — Sesuaikan dengan lokasi file Anda
# ============================================================

# Opsi 1: Jika di Google Colab, upload file JSON terlebih dahulu
# from google.colab import files
# uploaded = files.upload()

# Opsi 2: Jika file ada di Google Drive
# from google.colab import drive
# drive.mount('/content/drive')
# DATA_DIR = '/content/drive/MyDrive/dataset/'

# Opsi 3: Jika di lokal
DATA_DIR = 'dataset/'

# File dataset yang akan digunakan (2 tahun terakhir)
FILE_PATHS = [
    os.path.join(DATA_DIR, 'nvdcve-2.0-2025.json', 'nvdcve-2.0-2025.json'),
    os.path.join(DATA_DIR, 'nvdcve-2.0-2026.json', 'nvdcve-2.0-2026.json'),
]

print('📁 File dataset yang akan dimuat:')
for fp in FILE_PATHS:
    exists = '✅' if os.path.exists(fp) else '❌'
    print(f'  {exists} {fp}')
```

```
📁 File dataset yang akan dimuat:
  ✅ dataset/nvdcve-2.0-2025.json/nvdcve-2.0-2025.json
  ✅ dataset/nvdcve-2.0-2026.json/nvdcve-2.0-2026.json
```

```
def parse_nvd_json(filepath):
    """
    Membaca file NVD JSON dan mengekstrak fitur-fitur relevan
    ke dalam list of dictionaries untuk dikonversi ke DataFrame.

    Setiap CVE diekstrak menjadi record flat dengan fitur:
    - Identitas (CVE ID, status, waktu publikasi)
    - Skor dan level keparahan (CVSS v3.1)
    - Kelemahan (CWE ID)
    - Vektor serangan
    - Deskripsi singkat
    """
    with open(filepath, 'r', encoding='utf-8') as f:
        data = json.load(f)

    records = []
    vulnerabilities = data.get('vulnerabilities', [])

    for vuln in vulnerabilities:
        cve = vuln.get('cve', {})

        # --- Identitas ---
        cve_id = cve.get('id', '')
        published = cve.get('published', '')
        last_modified = cve.get('lastModified', '')
        vuln_status = cve.get('vulnStatus', '')
        source_id = cve.get('sourceIdentifier', '')

        # --- Deskripsi ---
        descriptions = cve.get('descriptions', [])
        desc_en = ''
        for d in descriptions:
            if d.get('lang') == 'en':
                desc_en = d.get('value', '')
                break
```

```
                # --- CVSS v3.1 (metrik utama) ---
                metrics = cve.get('metrics', {})
                cvss31 = metrics.get('cvssMetricV31', [{}])
                if cvss31:
                    cvss_data = cvss31[0].get('cvssData', {})
                    base_score = cvss_data.get('baseScore', np.nan)
                    base_severity = cvss_data.get('baseSeverity', '')
                    vector_string = cvss_data.get('vectorString', '')
                    attack_vector = cvss_data.get('attackVector', '')
                    attack_complexity = cvss_data.get('attackComplexity', '')
                    privileges_required = cvss_data.get('privilegesRequired', '')
                    user_interaction = cvss_data.get('userInteraction', '')
                    confidentiality_impact = cvss_data.get('confidentialityImpact', '')
                    integrity_impact = cvss_data.get('integrityImpact', '')
                    availability_impact = cvss_data.get('availabilityImpact', '')
                    exploitability_score = cvss31[0].get('exploitabilityScore', np.nan)
                    impact_score = cvss31[0].get('impactScore', np.nan)
                else:
                    base_score = np.nan
                    base_severity = ''
                    vector_string = ''
                    attack_vector = ''
                    attack_complexity = ''
                    privileges_required = ''
                    user_interaction = ''
                    confidentiality_impact = ''
                    integrity_impact = ''
                    availability_impact = ''
                    exploitability_score = np.nan
                    impact_score = np.nan

                # --- CWE (kelemahan) ---
                weaknesses = cve.get('weaknesses', [])
                cwe_ids = []
                for w in weaknesses:
                    for d in w.get('description', []):
                        val = d.get('value', '')
                        if val.startswith('CWE-'):
                            cwe_ids.append(val)
                primary_cwe = cwe_ids[0] if cwe_ids else ''
                cwe_count = len(cwe_ids)

                # --- Konfigurasi (produk terdampak) ---
                configs = cve.get('configurations', [])
                has_config = len(configs) > 0

                # --- Referensi ---
                refs = cve.get('references', [])
                ref_count = len(refs)
                has_exploit_ref = any(
                    'Exploit' in (r.get('tags', []) if isinstance(r.get('tags'), list) else [])
                    for r in refs
                )

                records.append({
                    'cve_id': cve_id,
                    'published': published,
                    'last_modified': last_modified,
                    'vuln_status': vuln_status,
                    'source_identifier': source_id,
                    'description': desc_en,
                    'base_score': base_score,
                    'base_severity': base_severity,
                    'attack_vector': attack_vector,
                    'attack_complexity': attack_complexity,
                    'privileges_required': privileges_required,
                    'user_interaction': user_interaction,
                    'confidentiality_impact': confidentiality_impact,
                    'integrity_impact': integrity_impact,
                    'availability_impact': availability_impact,
                    'exploitability_score': exploitability_score,
                    'impact_score': impact_score,
                    'primary_cwe': primary_cwe,
                    'cwe_count': cwe_count,
                    'has_config': has_config,
                    'ref_count': ref_count,
                    'has_exploit_ref': has_exploit_ref,
```

```
                'desc_length': len(desc_en),
            })

    return records

# --- Load semua file ---
all_records = []
for fp in FILE_PATHS:
    if os.path.exists(fp):
        recs = parse_nvd_json(fp)
        all_records.extend(recs)
        print(f'✅ Loaded {len(recs):,} records dari {os.path.basename(fp)}')
    else:
        print(f'⚠️  File tidak ditemukan: {fp}')

df = pd.DataFrame(all_records)
print(f'\n📊 Total record yang dimuat: {len(df):,}')
```

```
✅ Loaded 44,367 records dari nvdcve-2.0-2025.json
✅ Loaded 19,296 records dari nvdcve-2.0-2026.json

📊 Total record yang dimuat: 63,663
```

---

3. Data Dictionary

Data Dictionary menjelaskan setiap fitur (kolom) yang diekstrak dari dataset NVD CVE. Ini penting agar setiap anggota kelompok memahami makna teknis kolom dalam konteks keamanan.

No	Nama Fitur	Tipe Data	Makna Keamanan	Status	Catatan Risiko
1	`cve_id`	String	Identitas unik kerentanan global (misal: CVE-2026-0544)	ID / Metadata	Tidak digunakan sebagai fitur model
2	`published`	Datetime	Waktu kerentanan pertama kali dipublikasikan ke NVD	Metadata	Perlu konversi datetime
3	`vuln_status`	Kategorikal	Status analisis CVE (Analyzed, Modified, Awaiting Analysis)	Fitur	Distribusi bisa tidak seimbang
4	`base_score`	Numerik (0-10)	**Skor keparahan CVSS v3.1** — metrik utama tingkat bahaya	**Fitur Utama**	Ada missing values pada CVE tanpa skor
5	`base_severity`	Kategorikal	**Label keparahan** (NONE/LOW/MEDIUM/HIGH/CRITICAL)	**Label/Target**	Class imbalance signifikan
6	`attack_vector`	Kategorikal	Jalur serangan: NETWORK, ADJACENT, LOCAL, PHYSICAL	Fitur	Mayoritas NETWORK
7	`attack_complexity`	Kategorikal	Tingkat kesulitan eksploitasi: LOW, HIGH	Fitur	—
8	`privileges_required`	Kategorikal	Level hak akses yang dibutuhkan: NONE, LOW, HIGH	Fitur	—
9	`user_interaction`	Kategorikal	Apakah butuh interaksi user: NONE, REQUIRED	Fitur	—
10	`confidentiality_impact`	Kategorikal	Dampak pada kerahasiaan data: NONE, LOW, HIGH	Fitur	—
11	`integrity_impact`	Kategorikal	Dampak pada integritas data: NONE, LOW, HIGH	Fitur	—
12	`availability_impact`	Kategorikal	Dampak pada ketersediaan sistem: NONE, LOW, HIGH	Fitur	—
13	`exploitability_score`	Numerik (0-4)	Skor kemudahan eksploitasi kerentanan	Fitur	Turunan dari vektor CVSS
14	`impact_score`	Numerik (0-6)	Skor besarnya dampak jika berhasil dieksploitasi	Fitur	Turunan dari vektor CVSS
15	`primary_cwe`	Kategorikal	**Jenis kelemahan utama** (misal CWE-79 = XSS, CWE-89 = SQLi)	Fitur	Ratusan kategori, perlu grouping
16	`cwe_count`	Numerik	Jumlah CWE yang terkait dengan CVE	Fitur	—
17	`has_config`	Boolean	Apakah ada informasi produk terdampak	Fitur	—
18	`ref_count`	Numerik	Jumlah referensi/sumber informasi tentang CVE	Fitur	—
19	`has_exploit_ref`	Boolean	**Apakah ada referensi exploit publik**	Fitur	Penting untuk threat assessment
20	`desc_length`	Numerik	Panjang deskripsi kerentanan (karakter)	Fitur	—

⚠️ Potensi Data Leakage

- `base_score` dan `base_severity` saling terkait langsung (severity diturunkan dari score). Jika model memprediksi severity, `base_score` **harus dihapus** karena membocorkan label.
- `exploitability_score` dan `impact_score` adalah komponen pembentuk `base_score`, sehingga juga bisa menjadi leakage.

---

4. Data Profiling

Tahap ini menganalisis bentuk, kualitas, dan karakteristik dasar dataset.

4.1 Struktur Dataset (Shape & Info)

```
print('=' * 60)
print('📐 DIMENSI DATASET')
print('=' * 60)
print(f'Jumlah baris (record)  : {df.shape[0]:,}')
print(f'Jumlah kolom (fitur)   : {df.shape[1]}')
print(f'Total sel data         : {df.shape[0] * df.shape[1]:,}')

print('\n' + '=' * 60)
print('📋 INFORMASI KOLOM')
print('=' * 60)
df.info()
```

```
============================================================
📐 DIMENSI DATASET
============================================================
Jumlah baris (record)  : 63,663
Jumlah kolom (fitur)   : 23
Total sel data         : 1,464,249

============================================================
📋 INFORMASI KOLOM
============================================================
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 63663 entries, 0 to 63662
Data columns (total 23 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   cve_id                  63663 non-null  object
 1   published               63663 non-null  object
 2   last_modified           63663 non-null  object
 3   vuln_status             63663 non-null  object
 4   source_identifier       63663 non-null  object
 5   description             63663 non-null  object
 6   base_score              57194 non-null  float64
 7   base_severity           63663 non-null  object
 8   attack_vector           63663 non-null  object
 9   attack_complexity       63663 non-null  object
 10  privileges_required     63663 non-null  object
 11  user_interaction        63663 non-null  object
 12  confidentiality_impact  63663 non-null  object
 13  integrity_impact        63663 non-null  object
 14  availability_impact     63663 non-null  object
 15  exploitability_score    57194 non-null  float64
 16  impact_score            57194 non-null  float64
 17  primary_cwe             63663 non-null  object
 18  cwe_count               63663 non-null  int64
 19  has_config              63663 non-null  bool
 20  ref_count               63663 non-null  int64
 21  has_exploit_ref         63663 non-null  bool
 22  desc_length             63663 non-null  int64
dtypes: bool(2), float64(3), int64(3), object(15)
memory usage: 10.3+ MB
```

```
# Tampilkan 5 baris pertama
print('🔍 Preview 5 baris pertama:')
df.head()
```

🔍 Preview 5 baris pertama:

	cve_id	published	last_modified	vuln_status	source_identifier	description	base_score	base_severity	attacl
0	CVE-2025-0168	2025-01-01T14:15:23.590	2025-02-25T21:26:07.113	Analyzed	cna@vuldb.com	A vulnerability classified as critical has bee...	6.3	MEDIUM	N
1	CVE-2025-22214	2025-01-02T04:15:06.277	2026-04-15T00:35:42.020	Deferred	cve@mitre.org	Landray EIS 2001 through 2006 allows Message/f...	4.3	MEDIUM	N
2	CVE-2025-0171	2025-01-02T15:15:25.550	2025-04-03T14:20:30.043	Analyzed	cna@vuldb.com	A vulnerability, which was classified as criti...	6.3	MEDIUM	N
3	CVE-2025-0172	2025-01-02T16:15:09.103	2025-04-03T14:16:52.537	Analyzed	cna@vuldb.com	A vulnerability has been found in code-project...	6.3	MEDIUM	N
4	CVE-2025-0173	2025-01-02T18:15:21.630	2025-02-10T14:44:21.583	Analyzed	cna@vuldb.com	A vulnerability was found in SourceCodester On...	6.3	MEDIUM	N

5 rows × 23 columns

4.2 Missing Values

```
print('=' * 60)
print('🕳️  ANALISIS MISSING VALUES')
print('=' * 60)

# Hitung missing: NaN untuk numerik, string kosong untuk kategorikal
missing_nan = df.isna().sum()
missing_empty = (df == '').sum()
missing_total = missing_nan + missing_empty
missing_pct = (missing_total / len(df) * 100).round(2)

missing_report = pd.DataFrame({
    'NaN': missing_nan,
    'Empty String': missing_empty,
    'Total Missing': missing_total,
    'Persen (%)': missing_pct
})

# Tampilkan hanya kolom yang memiliki missing
has_missing = missing_report[missing_report['Total Missing'] > 0].sort_values('Total Missing', ascending=False)
if len(has_missing) > 0:
    print(has_missing.to_string())
    print(f'\n⚠️  {len(has_missing)} kolom memiliki data yang hilang.')
else:
    print('✅ Tidak ada missing values.')

print(f'\n📌 Interpretasi:')
print('  - Missing pada base_score/base_severity = CVE belum dianalisis CVSS.')
print('  - Missing pada primary_cwe = kelemahan belum diklasifikasi.')
print('  - Missing pada attack_vector = vektor CVSS belum ditetapkan.')
```

```
============================================================
🕳️  ANALISIS MISSING VALUES
============================================================
                       NaN  Empty String  Total Missing  Persen (%)
base_score            6469             0           6469       10.16
base_severity            0          6469           6469       10.16
attack_vector            0          6469           6469       10.16
attack_complexity        0          6469           6469       10.16
privileges_required      0          6469           6469       10.16
user_interaction         0          6469           6469       10.16
confidentiality_impact   0          6469           6469       10.16
integrity_impact         0          6469           6469       10.16
availability_impact      0          6469           6469       10.16
exploitability_score  6469             0           6469       10.16
impact_score          6469             0           6469       10.16
primary_cwe              0          4757           4757        7.47
```

```
⚠️  12 kolom memiliki data yang hilang.

📌 Interpretasi:
  - Missing pada base_score/base_severity = CVE belum dianalisis CVSS.
  - Missing pada primary_cwe = kelemahan belum diklasifikasi.
  - Missing pada attack_vector = vektor CVSS belum ditetapkan.
```

4.3 Duplikasi Data

```
print('=' * 60)
print('🔄 ANALISIS DUPLIKASI')
print('=' * 60)

dup_all = df.duplicated().sum()
dup_cve = df.duplicated(subset=['cve_id']).sum()

print(f'Baris duplikat (semua kolom)   : {dup_all:,}')
print(f'CVE ID duplikat                : {dup_cve:,}')

if dup_cve > 0:
    print(f'\n⚠️  Terdapat {dup_cve} CVE ID yang muncul lebih dari sekali.')
    print('Contoh duplikat:')
    dup_ids = df[df.duplicated(subset=['cve_id'], keep=False)].sort_values('cve_id')
    print(dup_ids[['cve_id', 'published', 'vuln_status', 'base_score']].head(10))
else:
    print('✅ Tidak ada CVE ID duplikat.')

print(f'\n📌 Interpretasi:')
print('  - Duplikasi CVE ID menandakan record yang di-update pada feed berbeda.')
print('  - Keputusan: hapus duplikat, pertahankan record terbaru (last_modified).')
```

```
============================================================
🔄 ANALISIS DUPLIKASI
============================================================
Baris duplikat (semua kolom)   : 0
CVE ID duplikat                : 0
✅ Tidak ada CVE ID duplikat.

📌 Interpretasi:
  - Duplikasi CVE ID menandakan record yang di-update pada feed berbeda.
  - Keputusan: hapus duplikat, pertahankan record terbaru (last_modified).
```

4.4 Statistik Deskriptif (Fitur Numerik)

```
print('=' * 60)
print('📈 STATISTIK DESKRIPTIF — FITUR NUMERIK')
print('=' * 60)

numeric_cols = ['base_score', 'exploitability_score', 'impact_score',
                'cwe_count', 'ref_count', 'desc_length']

stats = df[numeric_cols].describe().T
stats['median'] = df[numeric_cols].median()
stats['skew'] = df[numeric_cols].skew()
stats = stats[['count', 'mean', 'median', 'std', 'min', '25%', '50%', '75%', 'max', 'skew']]

print(stats.round(2).to_string())

print(f'\n📌 Interpretasi:')
print('  - base_score: periksa distribusi skor dan apakah ada konsentrasi pada rentang tertentu.')
print('  - ref_count & desc_length: skewness tinggi menandakan distribusi tidak normal (long tail).')
print('  - cwe_count: mayoritas CVE memiliki 1-2 CWE terkait.')
```

```
============================================================
📈 STATISTIK DESKRIPTIF — FITUR NUMERIK
============================================================
                       count    mean  median     std   min    25%    50%    75%     max  skew
base_score           57194.0    6.68     6.5    1.70   0.0    5.4    6.5    7.8    10.0 -0.10
exploitability_score 57194.0    2.66     2.8    0.92   0.1    1.8    2.8    3.9     3.9 -0.13
impact_score         57194.0    3.85     3.6    1.56   0.0    2.7    3.6    5.9     6.0 -0.02
cwe_count            63663.0    1.18     1.0    0.65   0.0    1.0    1.0    1.0     9.0  1.36
ref_count            63663.0    2.64     2.0    2.29   0.0    1.0    2.0    4.0    85.0  3.36
desc_length          63663.0  412.05   324.0  400.91  15.0  216.0  324.0  475.0  3998.0  4.87

📌 Interpretasi:
```

```
  - base_score: periksa distribusi skor dan apakah ada konsentrasi pada rentang tertentu.
  - ref_count & desc_length: skewness tinggi menandakan distribusi tidak normal (long tail).
  - cwe_count: mayoritas CVE memiliki 1-2 CWE terkait.
```

4.5 Distribusi Label / Target

```
print('=' * 60)
print('🏷️  DISTRIBUSI LABEL — BASE SEVERITY (CVSS v3.1)')
print('=' * 60)

# Filter hanya yang memiliki label severity
df_labeled = df[df['base_severity'] != ''].copy()

severity_order = ['NONE', 'LOW', 'MEDIUM', 'HIGH', 'CRITICAL']
label_counts = df_labeled['base_severity'].value_counts()
label_counts = label_counts.reindex(severity_order).dropna().astype(int)
label_pct = (label_counts / label_counts.sum() * 100).round(2)

label_report = pd.DataFrame({
    'Jumlah': label_counts,
    'Persentase (%)': label_pct
})
print(label_report.to_string())

print(f'\nTotal data berlabel  : {len(df_labeled):,}')
print(f'Total data tanpa label: {len(df) - len(df_labeled):,}')

# Hitung rasio imbalance
if len(label_counts) > 0:
    majority = label_counts.max()
    minority = label_counts.min()
    print(f'\n⚠️  Class Imbalance:')
    print(f'  Kelas mayoritas: {label_counts.idxmax()} ({majority:,})')
    print(f'  Kelas minoritas: {label_counts.idxmin()} ({minority:,})')
    print(f'  Rasio imbalance: {majority/minority:.1f} : 1')

print(f'\n📌 Interpretasi:')
print('  - Distribusi tidak seimbang: MEDIUM dan HIGH mendominasi.')
print('  - NONE dan LOW sangat sedikit → model bisa bias terhadap kelas mayoritas.')
print('  - Untuk modeling: gunakan F1-score, recall, dan class weighting, bukan accuracy.')
```

```
============================================================
🏷️  DISTRIBUSI LABEL — BASE SEVERITY (CVSS v3.1)
============================================================
              Jumlah  Persentase (%)
base_severity
NONE              20            0.03
LOW             2791            4.88
MEDIUM         27578           48.22
HIGH           21506           37.60
CRITICAL        5299            9.26

Total data berlabel  : 57,194
Total data tanpa label: 6,469

⚠️  Class Imbalance:
  Kelas mayoritas: MEDIUM (27,578)
  Kelas minoritas: NONE (20)
  Rasio imbalance: 1378.9 : 1

📌 Interpretasi:
  - Distribusi tidak seimbang: MEDIUM dan HIGH mendominasi.
  - NONE dan LOW sangat sedikit → model bisa bias terhadap kelas mayoritas.
  - Untuk modeling: gunakan F1-score, recall, dan class weighting, bukan accuracy.
```

---

5. Visualisasi EDA

Setiap visualisasi disertai **interpretasi** untuk menjawab pertanyaan keamanan.

5.1 Distribusi Label Severity (Bar Chart)

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
```

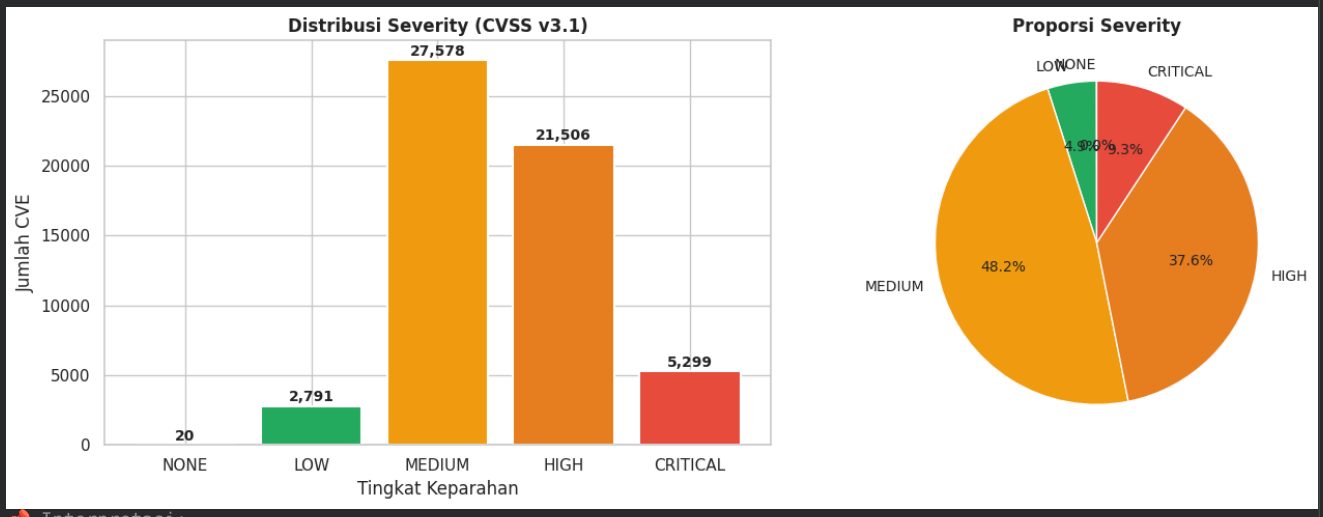
```
# --- Bar Chart ---
colors_severity = {
    'NONE': '#95a5a6',
    'LOW': '#27ae60',
    'MEDIUM': '#f39c12',
    'HIGH': '#e67e22',
    'CRITICAL': '#e74c3c'
}
bar_colors = [colors_severity.get(s, '#bdc3c7') for s in severity_order if s in label_counts.index]

ax1 = axes[0]
bars = ax1.bar(label_counts.index, label_counts.values, color=bar_colors, edgecolor='white', linewidth=1.5)
ax1.set_title('Distribusi Severity (CVSS v3.1)', fontweight='bold')
ax1.set_xlabel('Tingkat Keparahan')
ax1.set_ylabel('Jumlah CVE')
for bar, val in zip(bars, label_counts.values):
    ax1.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 100,
             f'{val:,}', ha='center', va='bottom', fontweight='bold', fontsize=10)

# --- Pie Chart ---
ax2 = axes[1]
ax2.pie(label_counts.values, labels=label_counts.index, colors=bar_colors,
        autopct='%1.1f%%', startangle=90, textprops={'fontsize': 10})
ax2.set_title('Proporsi Severity', fontweight='bold')

plt.tight_layout()
plt.savefig('viz_01_severity_distribution.png', bbox_inches='tight')
plt.show()

print('📌 Interpretasi:')
print('  - MEDIUM dan HIGH mendominasi dataset, menunjukkan mayoritas CVE berdampak sedang-tinggi.')
print('  - CRITICAL hanya ~5-10% — namun ini yang paling berdampak pada operasi keamanan.')
print('  - Class imbalance ini harus diatasi saat training model klasifikasi severity.')
```




```
📌 Interpretasi:
  - MEDIUM dan HIGH mendominasi dataset, menunjukkan mayoritas CVE berdampak sedang-tinggi.
  - CRITICAL hanya ~5-10% — namun ini yang paling berdampak pada operasi keamanan.
  - Class imbalance ini harus diatasi saat training model klasifikasi severity.
```

5.2 Distribusi Base Score (Histogram)

```
fig, ax = plt.subplots(figsize=(12, 5))

df_scored = df_labeled[df_labeled['base_score'].notna()]

ax.hist(df_scored['base_score'], bins=40, color='#3498db', edgecolor='white',
        alpha=0.85, linewidth=0.8)

# Garis batas severity
severity_thresholds = [
```

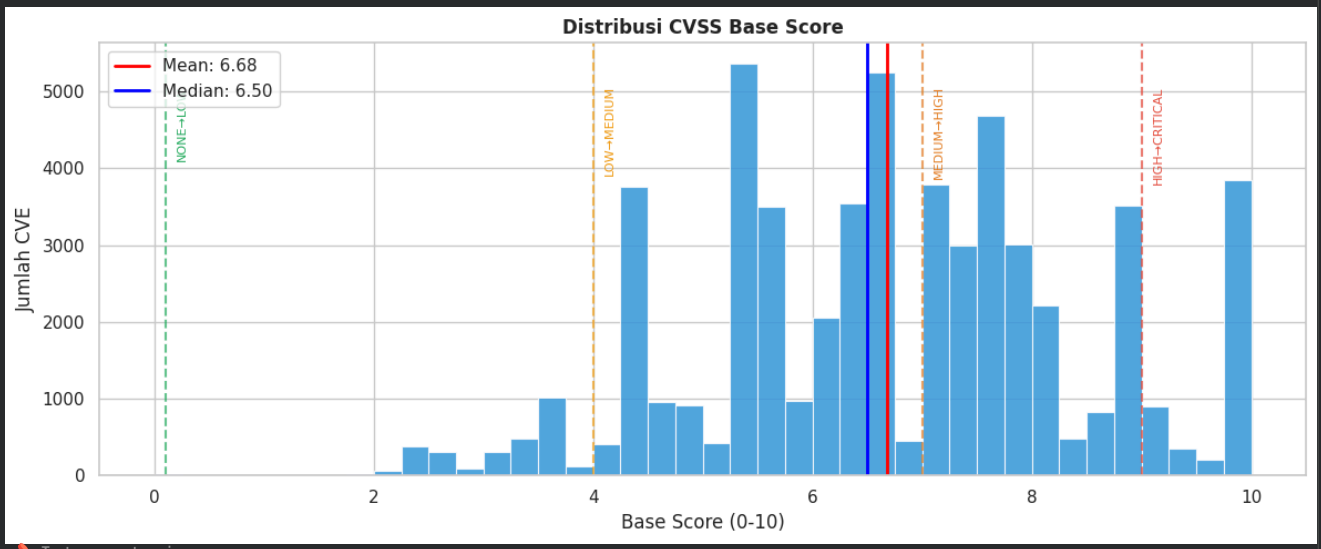
```
    (0.1, 'NONE→LOW', '#27ae60'),
    (4.0, 'LOW→MEDIUM', '#f39c12'),
    (7.0, 'MEDIUM→HIGH', '#e67e22'),
    (9.0, 'HIGH→CRITICAL', '#e74c3c')
]
for threshold, label, color in severity_thresholds:
    ax.axvline(x=threshold, color=color, linestyle='--', linewidth=1.5, alpha=0.7)
    ax.text(threshold + 0.1, ax.get_ylim()[1] * 0.9, label, color=color,
            fontsize=8, rotation=90, va='top')

ax.set_title('Distribusi CVSS Base Score', fontweight='bold')
ax.set_xlabel('Base Score (0-10)')
ax.set_ylabel('Jumlah CVE')

# Statistik
mean_score = df_scored['base_score'].mean()
median_score = df_scored['base_score'].median()
ax.axvline(x=mean_score, color='red', linestyle='-', linewidth=2, label=f'Mean: {mean_score:.2f}')
ax.axvline(x=median_score, color='blue', linestyle='-', linewidth=2, label=f'Median: {median_score:.2f}')
ax.legend(loc='upper left')

plt.tight_layout()
plt.savefig('viz_02_base_score_histogram.png', bbox_inches='tight')
plt.show()

print('📌 Interpretasi:')
print(f'  - Mean score: {mean_score:.2f}, Median: {median_score:.2f}')
print('  - Distribusi menunjukkan konsentrasi pada rentang MEDIUM-HIGH (4.0–9.0).')
print('  - Beberapa peak/cluster menunjukkan kombinasi vektor CVSS yang sering terjadi.')
print('  - Distribusi bukan normal – perlu pertimbangan scaling/transformasi untuk modeling.')
```




```
📌 Interpretasi:
  - Mean score: 6.68, Median: 6.50
  - Distribusi menunjukkan konsentrasi pada rentang MEDIUM-HIGH (4.0–9.0).
  - Beberapa peak/cluster menunjukkan kombinasi vektor CVSS yang sering terjadi.
  - Distribusi bukan normal – perlu pertimbangan scaling/transformasi untuk modeling.
```

5.3 Top 15 CWE (Jenis Kerentanan)

```
# Top CWE
cwe_data = df[df['primary_cwe'] != '']['primary_cwe'].value_counts().head(15)

# Mapping nama CWE yang umum
cwe_names = {
    'CWE-79': 'XSS',
    'CWE-89': 'SQL Injection',
    'CWE-862': 'Missing Authorization',
    'CWE-22': 'Path Traversal',
    'CWE-74': 'Injection',
    'CWE-78': 'OS Command Injection',
```

```
    'CWE-94': 'Code Injection',
    'CWE-416': 'Use After Free',
    'CWE-918': 'SSRF',
    'CWE-77': 'Command Injection',
    'CWE-787': 'Out-of-bounds Write',
    'CWE-352': 'CSRF',
    'CWE-434': 'Unrestricted Upload',
    'CWE-125': 'Out-of-bounds Read',
    'CWE-200': 'Info Exposure',
    'CWE-120': 'Buffer Overflow',
    'CWE-269': 'Improper Privilege Mgmt',
    'CWE-287': 'Improper Authentication',
    'CWE-476': 'NULL Pointer Deref',
    'CWE-502': 'Deserialization',
    'CWE-401': 'Memory Leak',
    'CWE-863': 'Incorrect Authorization',
    'CWE-190': 'Integer Overflow',
}

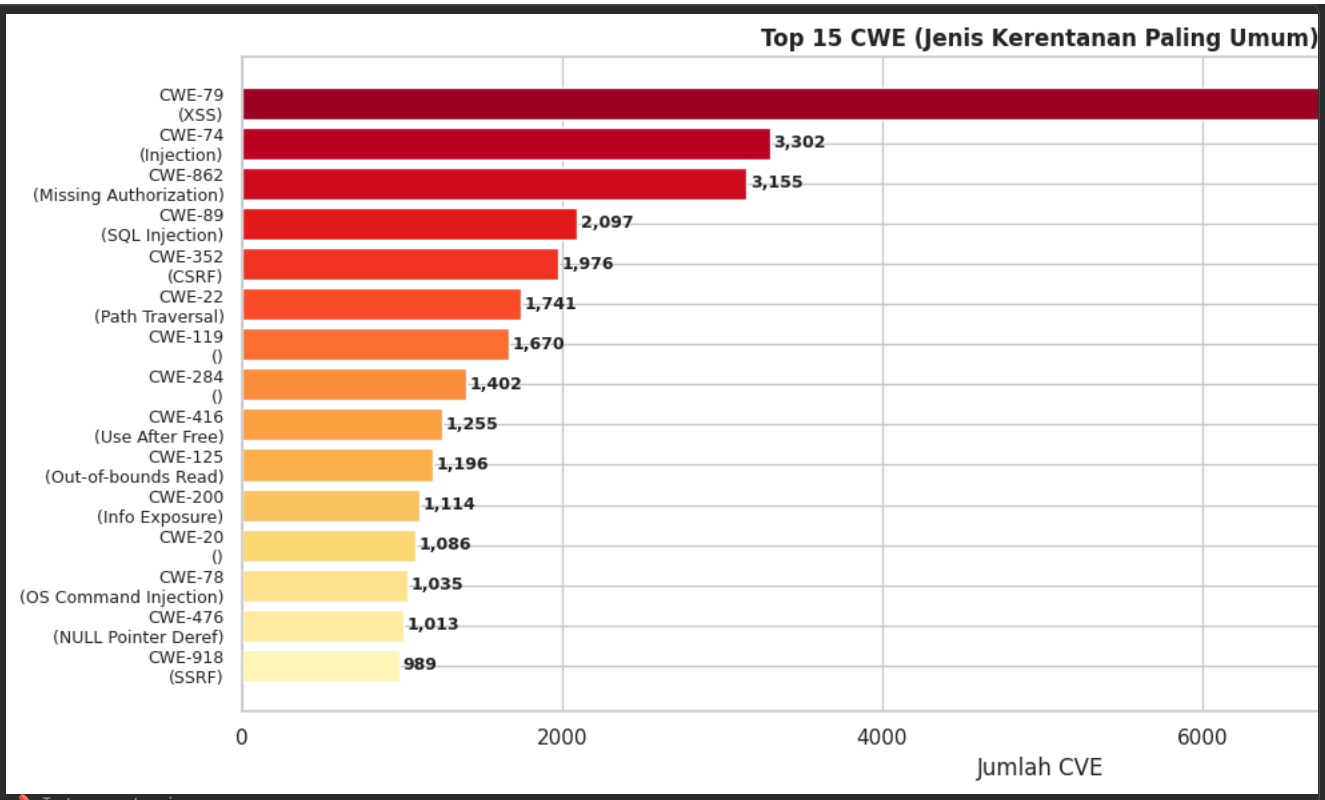
labels = [f'{cwe}\n({cwe_names.get(cwe, "")})' for cwe in cwe_data.index]

fig, ax = plt.subplots(figsize=(14, 6))
bars = ax.barh(range(len(cwe_data)), cwe_data.values,
               color=sns.color_palette('YlOrRd_r', len(cwe_data)), edgecolor='white')
ax.set_yticks(range(len(cwe_data)))
ax.set_yticklabels(labels, fontsize=9)
ax.invert_yaxis()
ax.set_xlabel('Jumlah CVE')
ax.set_title('Top 15 CWE (Jenis Kerentanan Paling Umum)', fontweight='bold')

for bar, val in zip(bars, cwe_data.values):
    ax.text(bar.get_width() + 20, bar.get_y() + bar.get_height()/2,
            f'{val:,}', va='center', fontsize=9, fontweight='bold')

plt.tight_layout()
plt.savefig('viz_03_top_cwe.png', bbox_inches='tight')
plt.show()

print('📌 Interpretasi:')
print('  - CWE-79 (XSS) dan CWE-89 (SQL Injection) mendominasi — ini relevan untuk RedSim.')
print('  - RedSim melakukan deteksi XSS dan SQLi pada URL yang dipindai.')
print('  - Kerentanan injeksi (CWE-74, 78, 94, 77) mendominasi top-10.')
print('  - Distribusi long-tail: banyak CWE dengan frekuensi rendah → perlu grouping untuk model.')
```




```
📌 Interpretasi:
  - CWE-79 (XSS) dan CWE-89 (SQL Injection) mendominasi — ini relevan untuk RedSim.
  - RedSim melakukan deteksi XSS dan SQLi pada URL yang dipindai.
  - Kerentanan injeksi (CWE-74, 78, 94, 77) mendominasi top-10.
  - Distribusi long-tail: banyak CWE dengan frekuensi rendah → perlu grouping untuk model.
```

5.4 Heatmap Korelasi Fitur Numerik

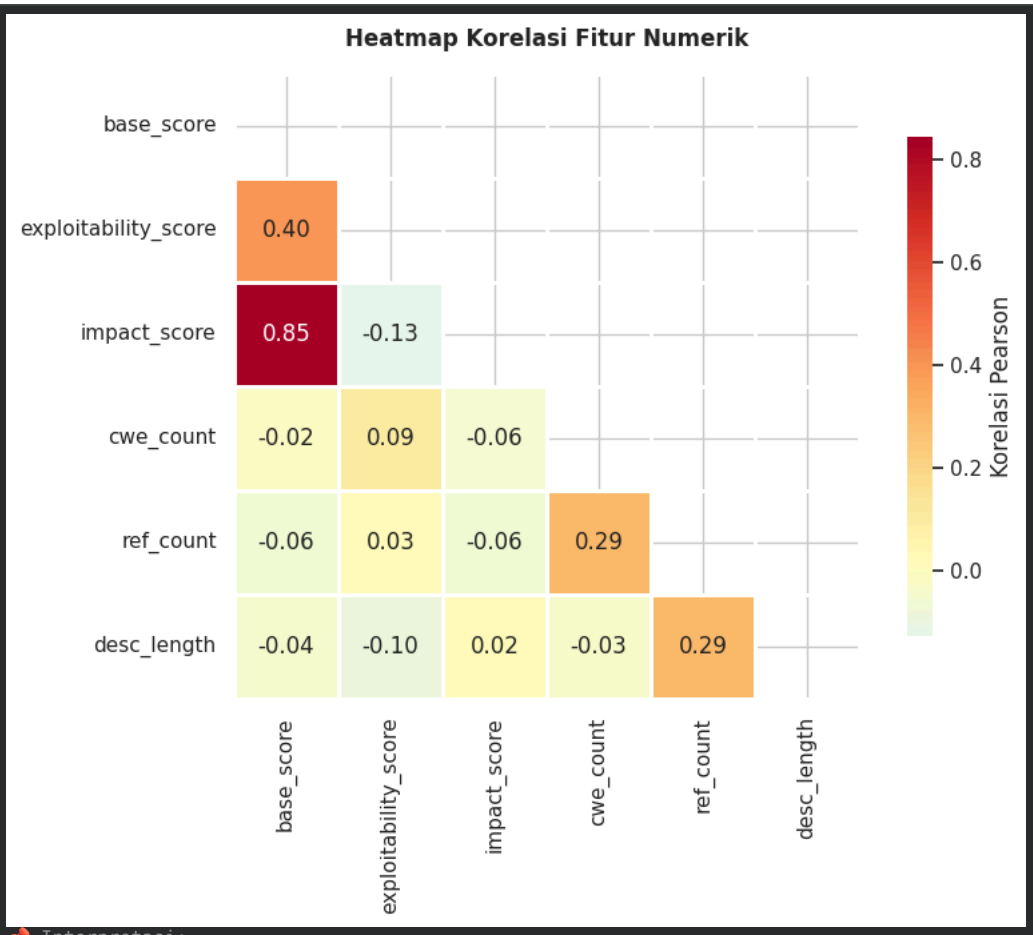
```
# Correlation heatmap untuk fitur numerik
corr_cols = ['base_score', 'exploitability_score', 'impact_score',
             'cwe_count', 'ref_count', 'desc_length']

corr_matrix = df[corr_cols].corr()

fig, ax = plt.subplots(figsize=(9, 7))
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
sns.heatmap(corr_matrix, mask=mask, annot=True, fmt='.2f', cmap='RdYlBu_r',
            center=0, square=True, linewidths=1, ax=ax,
            cbar_kws={'shrink': 0.8, 'label': 'Korelasi Pearson'})
ax.set_title('Heatmap Korelasi Fitur Numerik', fontweight='bold', pad=15)

plt.tight_layout()
plt.savefig('viz_04_correlation_heatmap.png', bbox_inches='tight')
plt.show()

print('📌 Interpretasi:')
print('  - base_score berkorelasi kuat dengan impact_score → masuk akal secara CVSS.')
print('  - exploitability_score juga berkorelasi dengan base_score → komponen pembentuknya.')
print('  - ⚠️ DATA LEAKAGE: jika target = severity, maka base_score, exploitability_score,')
print('    dan impact_score harus dihapus karena severity langsung diturunkan dari skor.')
print('  - ref_count dan desc_length memiliki korelasi rendah → fitur independen.')
```




```
📌 Interpretasi:
  - base_score berkorelasi kuat dengan impact_score → masuk akal secara CVSS.
  - exploitability_score juga berkorelasi dengan base_score → komponen pembentuknya.
  - ⚠️ DATA LEAKAGE: jika target = severity, maka base_score, exploitability_score,
    dan impact_score harus dihapus karena severity langsung diturunkan dari skor.
  - ref_count dan desc_length memiliki korelasi rendah → fitur independen.
```

5.5 Attack Vector vs Severity (Stacked Bar)

```
# Crosstab: Attack Vector vs Severity
ct = pd.crosstab(df_labeled['attack_vector'], df_labeled['base_severity'])

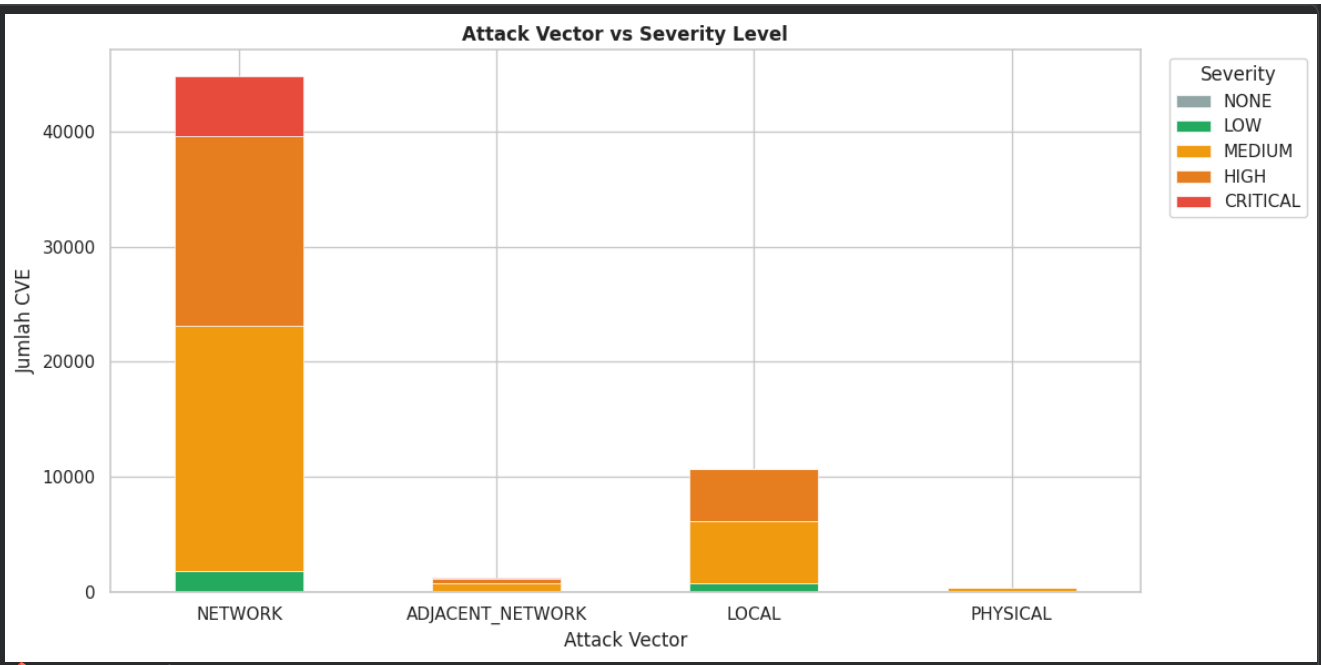
# Reorder
av_order = ['NETWORK', 'ADJACENT_NETWORK', 'LOCAL', 'PHYSICAL']
ct = ct.reindex(index=[x for x in av_order if x in ct.index],
                columns=[x for x in severity_order if x in ct.columns])

fig, ax = plt.subplots(figsize=(12, 6))
ct.plot(kind='bar', stacked=True, ax=ax,
        color=[colors_severity.get(s, '#bdc3c7') for s in ct.columns],
        edgecolor='white', linewidth=0.5)

ax.set_title('Attack Vector vs Severity Level', fontweight='bold')
ax.set_xlabel('Attack Vector')
ax.set_ylabel('Jumlah CVE')
ax.legend(title='Severity', bbox_to_anchor=(1.02, 1), loc='upper left')
ax.set_xticklabels(ax.get_xticklabels(), rotation=0)

plt.tight_layout()
plt.savefig('viz_05_attack_vector_severity.png', bbox_inches='tight')
plt.show()

print('📌 Interpretasi:')
print('  - NETWORK mendominasi — mayoritas kerentanan dapat dieksploitasi dari jaringan.')
print('  - Ini relevan untuk RedSim karena target scan adalah URL/website (network-based).')
print('  - Kerentanan LOCAL dan PHYSICAL lebih jarang tapi tetap bisa berdampak tinggi.')
print('  - Proporsi CRITICAL lebih tinggi pada NETWORK dibanding vektor lain.')
```




```
📌 Interpretasi:
  - NETWORK mendominasi — mayoritas kerentanan dapat dieksploitasi dari jaringan.
  - Ini relevan untuk RedSim karena target scan adalah URL/website (network-based).
  - Kerentanan LOCAL dan PHYSICAL lebih jarang tapi tetap bisa berdampak tinggi.
  - Proporsi CRITICAL lebih tinggi pada NETWORK dibanding vektor lain.
```

5.6 Tren Publikasi CVE per Bulan (Line Chart)

```
# Konversi datetime
df['pub_date'] = pd.to_datetime(df['published'], errors='coerce')
df['pub_month'] = df['pub_date'].dt.to_period('M')

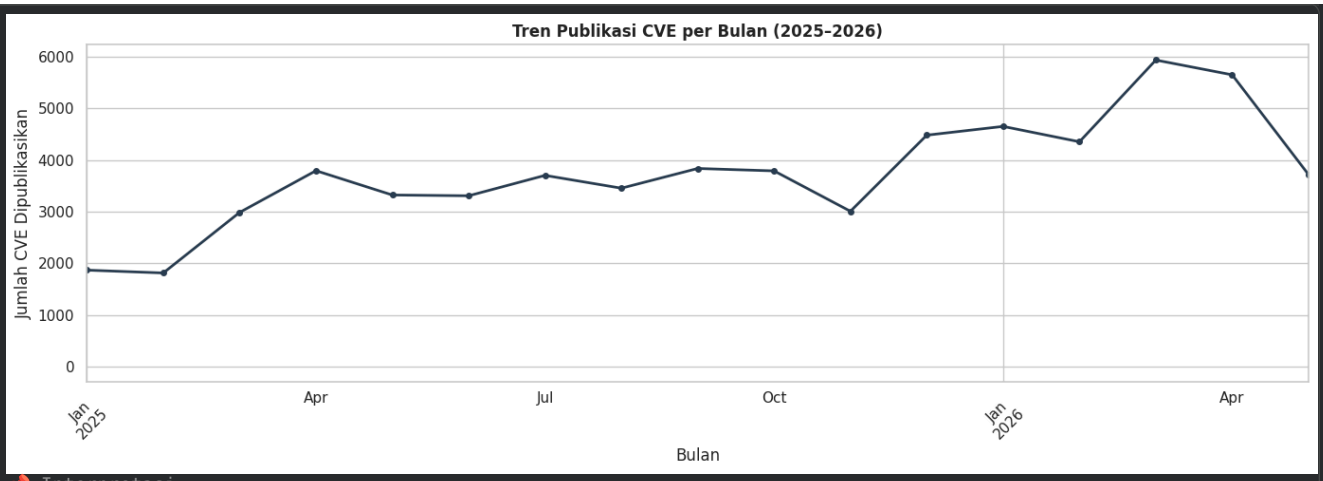
monthly = df.groupby('pub_month').size()

fig, ax = plt.subplots(figsize=(14, 5))
monthly.plot(kind='line', ax=ax, color='#2c3e50', linewidth=2, marker='o', markersize=4)
ax.fill_between(range(len(monthly)), monthly.values, alpha=0.15, color='#3498db')
ax.set_title('Tren Publikasi CVE per Bulan (2025–2026)', fontweight='bold')
ax.set_xlabel('Bulan')
ax.set_ylabel('Jumlah CVE Dipublikasikan')

# Tandai puncak
peak_idx = monthly.values.argmax()
ax.annotate(f'Puncak: {monthly.values[peak_idx]:,}',
            xy=(peak_idx, monthly.values[peak_idx]),
            xytext=(peak_idx + 1, monthly.values[peak_idx] + 200),
            arrowprops=dict(arrowstyle='->', color='red'),
            fontsize=10, color='red', fontweight='bold')

plt.xticks(rotation=45)
plt.tight_layout()
plt.savefig('viz_06_monthly_trend.png', bbox_inches='tight')
plt.show()

print('📌 Interpretasi:')
print('  - Tren menunjukkan jumlah CVE terus meningkat setiap tahun.')
print('  - Puncak publikasi biasanya di pertengahan tahun (patch cycle vendor besar).')
print('  - Data temporal ini penting: RedSim perlu knowledge base yang selalu diperbarui.')
```




```
📌 Interpretasi:
  - Tren menunjukkan jumlah CVE terus meningkat setiap tahun.
  - Puncak publikasi biasanya di pertengahan tahun (patch cycle vendor besar).
  - Data temporal ini penting: RedSim perlu knowledge base yang selalu diperbarui.
```

5.7 Boxplot: Outlier Detection pada Skor Numerik

```
fig, axes = plt.subplots(1, 3, figsize=(15, 5))

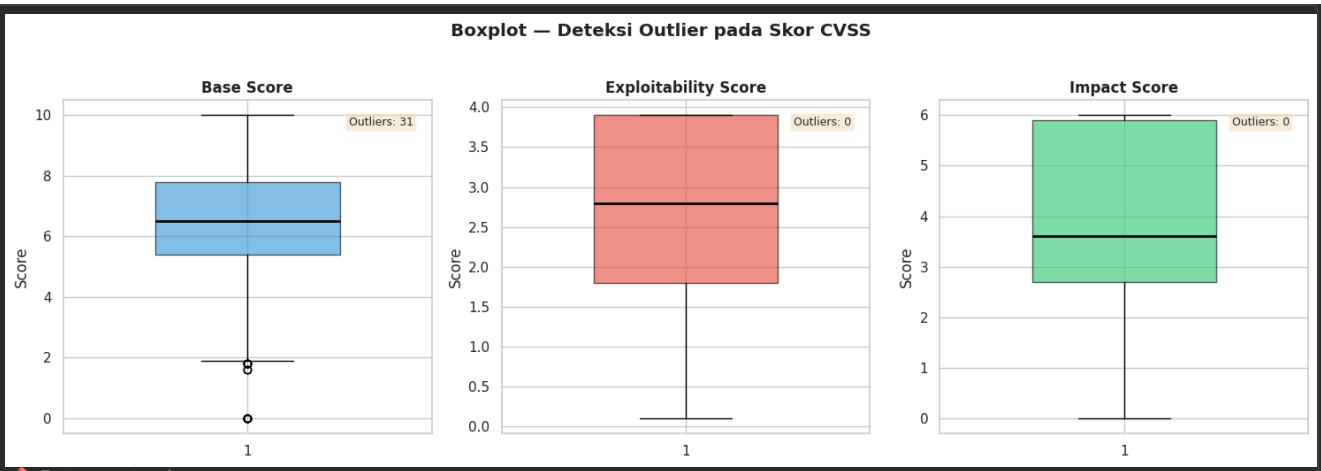
box_features = [
    ('base_score', 'Base Score', '#3498db'),
    ('exploitability_score', 'Exploitability Score', '#e74c3c'),
    ('impact_score', 'Impact Score', '#2ecc71')
]

for ax, (col, title, color) in zip(axes, box_features):
    data = df_labeled[col].dropna()
    bp = ax.boxplot(data, patch_artist=True, widths=0.5,
                    boxprops=dict(facecolor=color, alpha=0.6),
                    medianprops=dict(color='black', linewidth=2))
    ax.set_title(title, fontweight='bold')
    ax.set_ylabel('Score')

    # Statistik
    q1 = data.quantile(0.25)
    q3 = data.quantile(0.75)
    iqr = q3 - q1
    outliers = ((data < q1 - 1.5*iqr) | (data > q3 + 1.5*iqr)).sum()
    ax.text(0.95, 0.95, f'Outliers: {outliers:,}',
            transform=ax.transAxes, ha='right', va='top',
            fontsize=9, bbox=dict(boxstyle='round', facecolor='wheat', alpha=0.5))

plt.suptitle('Boxplot — Deteksi Outlier pada Skor CVSS', fontweight='bold', y=1.02)
plt.tight_layout()
plt.savefig('viz_07_boxplot_outliers.png', bbox_inches='tight')
plt.show()

print('📌 Interpretasi:')
print('  - Base score: distribusi relatif merata di rentang 4-10, sedikit outlier di bawah.')
print('  - Exploitability & impact score: terkait langsung dengan komponen vektor CVSS.')
print('  - Outlier pada skor ini bukan noise, melainkan CVE dengan karakteristik unik.')
print('  - Keputusan: pertahankan outlier, karena secara domain keamanan mereka valid.')
```




```
📌 Interpretasi:
  - Base score: distribusi relatif merata di rentang 4-10, sedikit outlier di bawah.
  - Exploitability & impact score: terkait langsung dengan komponen vektor CVSS.
  - Outlier pada skor ini bukan noise, melainkan CVE dengan karakteristik unik.
  - Keputusan: pertahankan outlier, karena secara domain keamanan mereka valid.
```

5.8 Scatter Plot: Exploitability vs Impact Score

```
fig, ax = plt.subplots(figsize=(10, 8))

# Ambil sample untuk visual yang lebih jelas
sample = df_labeled.dropna(subset=['exploitability_score', 'impact_score']).sample(
    min(5000, len(df_labeled)), random_state=42
)

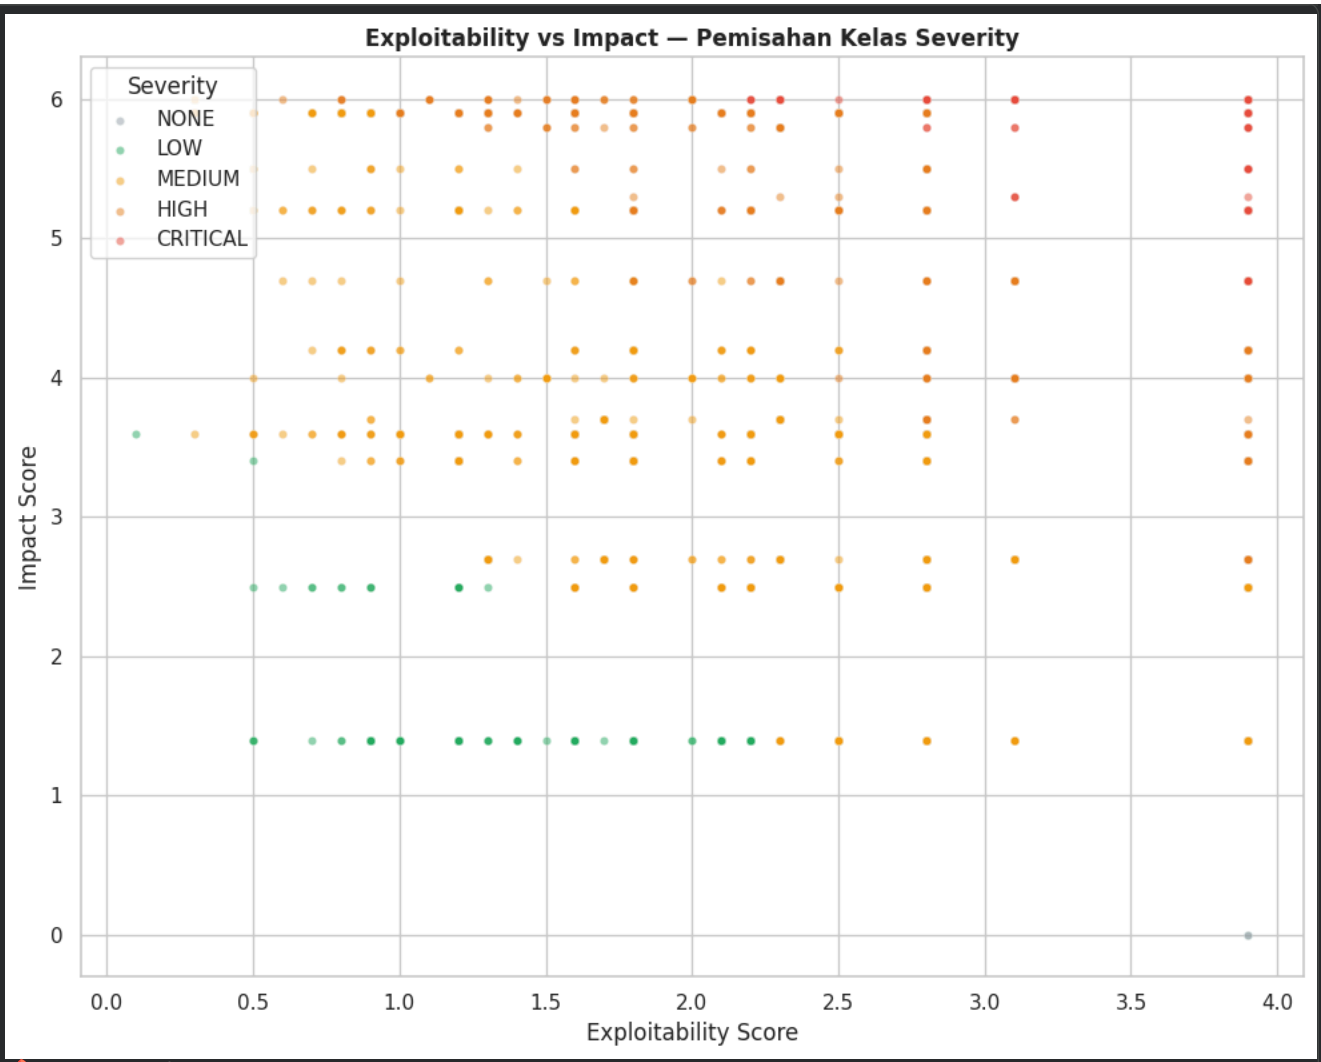
severity_color_map = {
    'NONE': '#95a5a6', 'LOW': '#27ae60', 'MEDIUM': '#f39c12',
    'HIGH': '#e67e22', 'CRITICAL': '#e74c3c'
}

for sev in severity_order:
    mask = sample['base_severity'] == sev
    if mask.sum() > 0:
        ax.scatter(sample.loc[mask, 'exploitability_score'],
                   sample.loc[mask, 'impact_score'],
                   c=severity_color_map[sev], label=sev,
                   alpha=0.5, s=20, edgecolors='white', linewidth=0.3)

ax.set_xlabel('Exploitability Score', fontsize=12)
ax.set_ylabel('Impact Score', fontsize=12)
ax.set_title('Exploitability vs Impact — Pemisahan Kelas Severity', fontweight='bold')
ax.legend(title='Severity', loc='upper left')

plt.tight_layout()
plt.savefig('viz_08_scatter_exploitability_impact.png', bbox_inches='tight')
plt.show()

print('📌 Interpretasi:')
print('  - Scatter plot menunjukkan cluster yang cukup terpisah antar severity level.')
print('  - CRITICAL cenderung memiliki exploitability dan impact tinggi secara bersamaan.')
print('  - MEDIUM tersebar luas — menunjukkan variasi kombinasi vektor yang beragam.')
print('  - Pola cluster ini menunjukkan model klasifikasi berpotensi bekerja baik.')
```




```
📌 Interpretasi:
  - Scatter plot menunjukkan cluster yang cukup terpisah antar severity level.
  - CRITICAL cenderung memiliki exploitability dan impact tinggi secara bersamaan.
  - MEDIUM tersebar luas — menunjukkan variasi kombinasi vektor yang beragam.
  - Pola cluster ini menunjukkan model klasifikasi berpotensi bekerja baik.
```

---

6. Temuan EDA & Dampak pada Preprocessing

Berdasarkan analisis EDA di atas, berikut adalah **5 temuan utama** beserta dampaknya:

```
temuan = [
    {
        'no': 1,
        'temuan': 'Missing Values pada CVSS Metrics',
        'detail': f'Sekitar {(df["base_score"].isna().sum() + (df["base_severity"]=="").sum()):,} CVE tidak memiliki
        'dampak': 'Drop record tanpa skor, atau gunakan sebagai kelas "Unscored" terpisah.',
        'bukti': 'Lihat Section 4.2 — Analisis Missing Values'
    },
    {
        'no': 2,
        'temuan': 'Class Imbalance Signifikan pada Label Severity',
        'detail': 'MEDIUM dan HIGH mendominasi (>70%), sementara NONE dan LOW sangat sedikit.',
        'dampak': 'Gunakan F1-score/recall sebagai metrik utama. Terapkan SMOTE, class_weight, atau stratified sampli
        'bukti': 'Lihat Section 4.5 & Visualisasi 5.1'
    },
    {
        'no': 3,
        'temuan': 'Data Leakage antara base_score dan base_severity',
        'detail': 'base_severity langsung diturunkan dari base_score (threshold-based). Korelasi mendekati 1.0.',
        'dampak': 'Jika target = severity: HAPUS base_score, exploitability_score, dan impact_score dari fitur.',
        'bukti': 'Lihat Section 5.4 — Heatmap Korelasi'
    },
    {
```

```
        'no': 4,
        'temuan': 'Fitur Kategorikal CWE Memiliki Kardinalitas Tinggi',
        'detail': f'Terdapat {df[df["primary_cwe"] != ""]["primary_cwe"].nunique()} jenis CWE unik. Distribusi long-t
        'dampak': 'Grouping CWE ke kategori utama (Injection, Memory, Auth, etc.) sebelum encoding.',
        'bukti': 'Lihat Section 5.3 — Top 15 CWE'
    },
    {
        'no': 5,
        'temuan': 'Tren Temporal: Jumlah CVE Terus Meningkat',
        'detail': 'Data 2026 menunjukkan tren kenaikan jumlah kerentanan yang dipublikasikan per bulan.',
        'dampak': 'Model perlu di-retrain secara berkala. Knowledge base RedSim harus diperbarui.',
        'bukti': 'Lihat Section 5.6 — Tren Publikasi CVE'
    }
]

print('=' * 70)
print('📋 RINGKASAN TEMUAN EDA & DAMPAK PREPROCESSING')
print('=' * 70)

for t in temuan:
    print(f'\n🔹 Temuan {t["no"]}: {t["temuan"]}')
    print(f'   Detail  : {t["detail"]}')
    print(f'   Dampak  : {t["dampak"]}')
    print(f'   Bukti   : {t["bukti"]}')
    print('   ' + '-' * 65)
```

```
======================================================================
📋 RINGKASAN TEMUAN EDA & DAMPAK PREPROCESSING
======================================================================

🔹 Temuan 1: Missing Values pada CVSS Metrics
   Detail  : Sekitar 12,938 CVE tidak memiliki skor CVSS v3.1 (belum dianalisis NVD).
   Dampak  : Drop record tanpa skor, atau gunakan sebagai kelas "Unscored" terpisah.
   Bukti   : Lihat Section 4.2 — Analisis Missing Values
   -----------------------------------------------------------------

🔹 Temuan 2: Class Imbalance Signifikan pada Label Severity
   Detail  : MEDIUM dan HIGH mendominasi (>70%), sementara NONE dan LOW sangat sedikit.
   Dampak  : Gunakan F1-score/recall sebagai metrik utama. Terapkan SMOTE, class_weight, atau stratified sampling.
   Bukti   : Lihat Section 4.5 & Visualisasi 5.1
   -----------------------------------------------------------------

🔹 Temuan 3: Data Leakage antara base_score dan base_severity
   Detail  : base_severity langsung diturunkan dari base_score (threshold-based). Korelasi mendekati 1.0.
   Dampak  : Jika target = severity: HAPUS base_score, exploitability_score, dan impact_score dari fitur.
   Bukti   : Lihat Section 5.4 — Heatmap Korelasi
   -----------------------------------------------------------------
```